

基于正倒排索引的 Java 文档搜索引擎

通用问题

1. 为什么做这个项目？

- 回答1: 出于兴趣

日常生活中也经常使用搜索引擎, 对于搜索引擎技术如何实现的比较感兴趣.

通用搜索引擎依赖的数据较多, 需要通过爬虫技术来获取, 但是编写爬虫程序又存在法律风险. 而 Java 的 api 文档是可以从官网直接下载到完整版本的, 比较适合用来做搜索的数据.

- 回答2: 学校课设

看到学长(可以是其他学校)的课设/毕设是这样的主题, 因此就想自己也尝试一下看能否做出一个类似的效果.

2. 这个项目为啥和上个(之前)同学的项目一样？

- 回答1: 出于兴趣

调研搜索引擎原理的时候搜索了一些博客和开源项目, 参考其中的思路, 自行尝试实现.

其他同学也可能借鉴了类似博客 & 开源项目.

一定要体现出, "自行实现", 只是参考了思路.

- 回答2: 学校课设

调研过程中, 根据刷到的一些博客和开源项目, 参考其中的思路, 自行尝试实现.

其他同学也可能借鉴了类似博客 & 开源项目.

一定要体现出, "自行实现", 只是参考了思路.

(注: 以下内容需要同学自己思考项目扩展, 如不清楚, 不建议参照话术, 容易给自己挖坑. 说到上面的内容就可以了. 不要使用课上讲解的扩展, 大家都说一样的也不行)

但这个项目除了借鉴常规流程, 我还进行了 (功能扩展/性能优化/代码优化)(并解释一下扩展点)

可以参考的回答思路: 即使面试官的指控让你感到不舒服, 也要尽量保持冷静和专注. 无论情况如何, 保持专业和礼貌的态度是非常重要的。

- **诚实面对：** 如果确实使用了代码而没有适当的引用或修改，那么诚实地承认这一点，可以说是从 github 上找的开源项目，并解释你当时的想法和决策过程（参考答案举例）。同时，如果抄袭代码被面试官发现，要及时表明你已经认识到了这个问题，并在未来的工作中会更加注意。
- **展示学习过程：** 如果是面试官发现项目确实有抄袭现象，也可以说项目原本的一些问题，你进行了优化解决，体现自己有过思考，并解释问题与优化思路。
- **请求反馈：** 询问面试官对你的项目有什么具体的反馈或建议，这表明你愿意学习和改进。

3. 介绍一下这个项目

1. 项目背景&目标: 参考 "为什么做这个项目"
2. 个人角色: 独立完成整个项目的设计, 开发, 测试, 部署到云服务器的整个流程
3. 项目设计: 项目主要划分成下列模块
 - a. 索引模块: 针对 Java API 文档的 HTML 进行解析, 构建正排索引和倒排索引.
 - b. 搜索模块: 基于索引, 实现按查询词查找出匹配 HTML 文档的逻辑
 - c. Web 模块: 基于 Spring MVC, 搭建 HTTP 服务器, 提供 HTTP 接口, 编写前端页面
4. 项目难点: 对于搜索流程的理解, 对于索引结构的理解, 对于分词原理的理解

4. 你在这个项目中使用了哪些技术？为什么选择(决策)这些技术？

- Spring, 搭建 Java 服务器的主流技术.
- 正排索引&倒排索引, 搜索引擎中的核心数据结构
- ansj: 分词库. ansj 是一个使用简单方便, 效果也不错的分词库.

5. 项目最终的成果如何？你从这个项目中学到了什么？

该项目能够达成针对 Java API 文档的搜索效果.

通过这个项目, 进一步的了解了搜索引擎的工作原理, 对 Spring, HTTP, 文件操作, 数据结构等核心操作的理解有了进一步的提高, 锻炼了项目设计, 问题解决的能力.

6. 你在项目中扮演了什么角色？你负责了哪些模块或功能？

(比较简单的项目不应该是和别人合作完成的. 一定是独立完成.)

独立完成项目的设计, 实现, 测试.....

7. 在项目中，你是如何平衡技术实现和项目时间线的？这个项目做了多长时间？

这个项目我花了2个月来完成，从项目目标的确定，到项目原型图的敲定，到各个模块的拆分，在到最后的开发测试部署。

关于时间，其实我没有制定详细的规划。是因为我也是抱着学习的心态来完成这个项目。在开发中可能会遇到一些问题，解决问题也是我学习的过程，因此时间就不能确定下来。

回复思路可参考：

1. **明确项目范围和目标**：在项目开始之前，我确定了项目到底要做什么，对范围、目标和期望有清晰的认知。
2. **制定详细的计划（如果有）**：创建一个详细的项目计划，包括项目原型图的敲定，到前后端功能的拆分，前后端交互接口和各功能的联调截至时间。
3. **优先级排序**：确定哪些功能和特性是当下最重要的，并根据优先级进行排序。这有助于在时间有限的情况下做出决策。
4. **人员分配（如果有）**：由于前端是交付给其他同学完成，以上内容也需要和前端同学对齐。（如果说前端也是自己完成的，就不用说这一点）
5. **沟通和协作（如果有）**：确保和前端同学有良好的沟通和协作，以便快速解决问题并共享信息。（如果说前端也是自己完成的，就不用说这一点）
6. **质量保证**：计划中还包含足够的时间来测试项目，进行质量保证。

8. 你在项目中遇到了哪些挑战？你是如何识别和解决这些问题的？

- 针对搜索引擎实现原理的调研: 我参考了一些网上的资料和一些开源项目的代码, 发现别人介绍/编写的搜索引擎, 功能/流程大多比较复杂, 而此处我只需要一个比较简单的搜索引擎, 因此需要对功能进行提炼, 把最核心的部分提取出来并进行实现.
- 实现索引模块时, 制作索引消耗的时间比较长. 为了优化性能, 需要对整个过程的流程进行追踪定位, 并尝试了一些方案, 最终确定使用多线程制作的方式, 把索引制作时间从 xx 秒缩短到 xx 秒

上述只是提供一个切入的思路. 具体如何回答, 每个同学要结合自己做项目过程中的感受来组织语言.

面试官问这样的问题本质上就是试探同学是否是真的把项目做出来了, 还是抄来的.

切忌凭空编造! 很容易露馅!

9. 你是如何测试和部署项目的？

测试：

- 针对功能设计测试用例. 参考 "测试课程 - 测试用例设计"

强烈建议同学真实的去测试一下. 否则这样的问题很难回答.

部署:

1. 构建自动化: 通过 Maven 来编译代码和生成部署包。
2. 环境准备: 确保部署环境 (开发、生产) 都已正确设置。
3. 部署: 将包发布在阿里云服务器并后台启动
4. 日志: 部署后打印日志以便于问题诊断。

10. 你是如何优化项目性能的? 你有哪些性能调优的经验?

多线程制作索引: 基于线程池, 把每个文档读取出来之后都丢入到线程池中, 线程池中的工作线程负责解析文档和制作索引。目的是加快制作索引的速度。

11. 你是如何确保项目安全性的? 你使用了哪些安全措施?

该项目不涉及安全性

12. 你是如何设计项目以支持未来的扩展? 你是如何确保代码的可维护性的?

该项目的核心是 "数据".

当前使用 java api 文档作为输入数据, 就能构成一个 "java 文档搜索引擎"

如果通过爬虫的方式, 爬取到其他某网站的数据, 再针对这个数据做解析做索引, 就能构成其他网站的搜索引擎.

注意! 实现爬虫很可能涉嫌违法犯罪! 刑法中的 <非法控制计算机信息系统罪>, <非法破坏计算机信息系统罪>, <提供破坏计算机信息系统工具罪> 都是和爬虫相关, 尤其是最近几年抓的非常严. 如果面试官针对 "爬虫" 这个话题展开, 就可以通过这个说辞来应对.

专属问题

1. 描述一下搜索的流程?

- 分词: 针对用户输入的查询词进行分词
- 触发: 根据分词结果, 查倒排索引, 获取文档 id 列表
- 归并: 针对多个词触发的文档 id 进行归并, 把相同的 id 的触发结果合并成一个, 并提高权重.
- 排序: 根据权重的值降序排序

- 包装结果: 根据文档 id, 去正排索引中查找, 生成描述, 最终构造出完整的返回结果.

2. 你是如何实现的分词? 分词原理是什么?

- 基于词典: 中文语言词汇虽然数目众多, 但是对于计算机来说是可以穷尽枚举的.
- 基于概率统计: 根据语料库进行训练(比如近20年人民日报的所有内容), 统计相邻两个汉字出现的概率, 将概率高的汉字组合更新进入词典

当前我们直接使用了第三方库 `ansj`, 并未关注具体分词算法的实现.

3. 你将什么作为索引?

正排索引:

- 读取文档根目录, 遍历获取到所有 html 后缀的文档.
- 针对每个文档, 解析出标题, url, 正文. 解析正文的时候基于正则表达式, 去掉html 标签.
- 把分析结果构造成一个 `DocInfo` 对象, 尾插到正排索引数组中.

倒排索引:

- 针对标题和正文, 分别进行分词, 再遍历分词结果, 根据分词结果作为 key, 把对应的文档 id 列表作为 value, 通过哈希表维护起来.

写入文件:

- 遍历完所有的文档之后, 把内存中的正排和倒排索引序列化成 json 结果, 写入到文件中.

4. 正排索引和倒排索引的结构是什么样子的?

- 正排索引是 `docId => 文档详细信息` 的映射.
- 倒排索引是 `词 => 文档id 列表` 的映射.

这个结构最好能够让同学举例说明.

5. 词和文档的相关性是如何衡量的

通过词频衡量. 当前使用的公式是 `标题中出现的次数 * 10 + 正文中出现的次数` 来作为权重.

这里的计算方式是一个 "简单粗暴" 的办法. 更好的做法是通过 AI 的方式, 对 "词" 和 "文档" 之间的相关性进行预估. 这里的过程比较复杂. 有 AI 基础的同学可以尝试深入了解, 无 AI 基础的同学不必过多展开.

6. 例如一次输入两个词 A 和 B, 如果 A 和 B 的倒排拉链中都包含同一个文档, 此时如何处理呢

这样的文档包含多个查询词, 相关性理解成更高, 应该要排到更靠前的位置.

一个简单的做法是针对同一个文档进行权重合并.

比如遍历 A 的倒排拉链, 把这里的文档信息记录到一个哈希表中. 然后再遍历 B 的倒排拉链, 依次在 A 中查询

如果发现存在相同的文档, 则把两个文档的权重进行相加, 并且在最终合并多个拉链时进行去重

咱们实际项目中采取的是类似于 "链表多路归并" 这样的做法, 通过双指针从头到尾遍历两个倒排拉链, 发现重复的就进行合并权重操作. 本质上和上面是一样的.

比特就业课